Klasteryzacja – miary jakości klastrów

Wprowadzenie

Klasteryzacja jest jedną z podstawowych metod analizy danych w statystyce i uczeniu maszynowym. Polega na podziale zbioru obserwacji na rozłączne grupy zwane klastrami, w taki sposób, aby obiekty należące do tego samego klastra były do siebie możliwie najbardziej podobne, natomiast obiekty z różnych klastrów – możliwie najbardziej odległe.

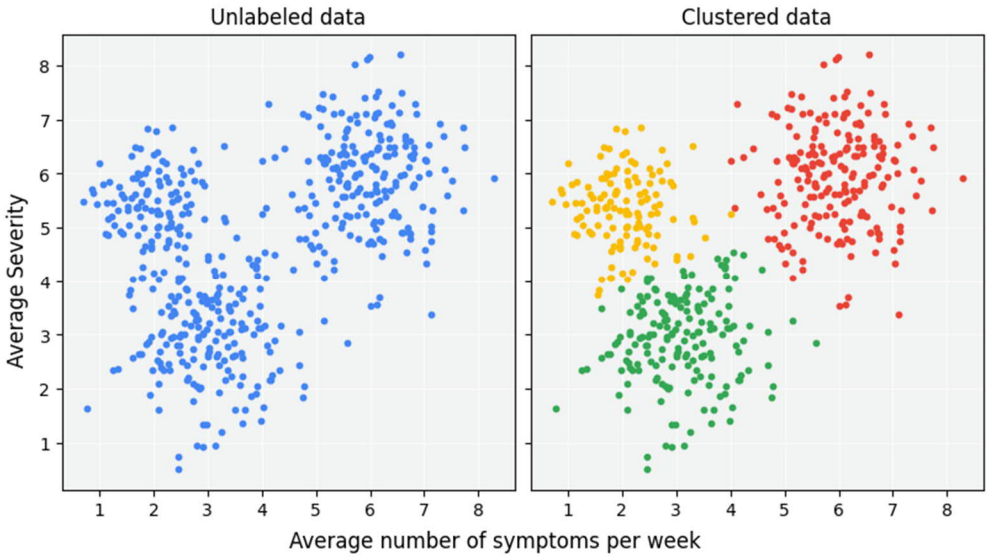

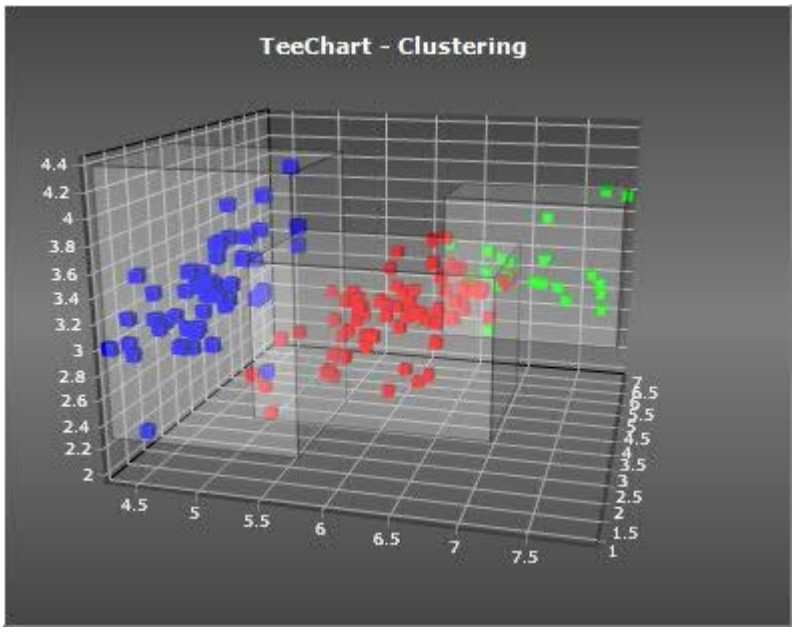

1. *Zła klasteryzacja, przyczyny*

Przedstawiona klasteryzacja charakteryzuje się niską separacją między klastrami oraz słabą spójnością wewnętrzną, co prowadzi do niejednoznacznych granic i błędnych przypisań obserwacji.

1. Brak separacji między klastrami

Klastry silnie na siebie nachodzą:

- punkty z różnych klastrów leżą bardzo blisko siebie,
- granice klastrów są niejednoznaczne.

Oznacza to niską separację, co utrudnia rozróżnienie grup.

2. Niska spójność wewnątrz klastrów

W obrębie jednego klastra:

- punkty są mocno rozproszone,
- odległości między punktami w tym samym klastrze są duże.

To prowadzi do słabej spójności (cohesion).

3. Centroidy nie reprezentują klastrów

Środki klastrów (centroidy):

- leżą w obszarach silnego nakładania się danych,

- nie są jednoznacznym „centrum” swoich grup.

Model źle reprezentuje strukturę danych.

2. Formalna definicja problemu klasteryzacji

Niech $X = \{x1, x2, \ldots, xn\}$ będzie zbiorem obserwacji w przestrzeni R^p. Celem klasteryzacji jest znalezienie podziału X na K rozłącznych podzbiorów $C = \{C1, C2, \ldots, CK\}$, takich że $Ci \cap Cj = \emptyset \; dla \; i \neq j \; oraz \; \cup \; Ci = X$.

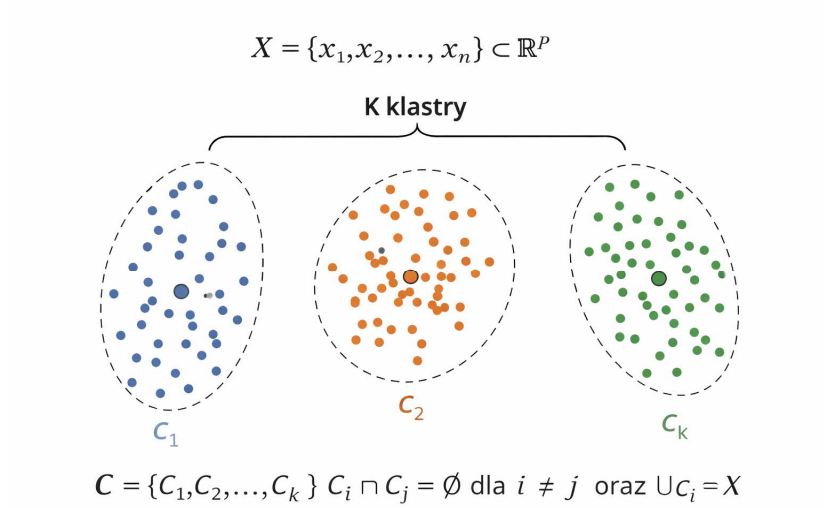

3. Spójność i separacja klastrów

Spójność (cohesion) opisuje stopień skupienia obserwacji wewnątrz klastra i często mierzona jest sumą kwadratów odległości punktów od centroidu klastra:

$$WCSS = \Sigma\Sigma||x - \mu k||^2.$$

Separacja (separation) mierzy odległość pomiędzy klastrami, np. poprzez odległość pomiędzy centroidami.

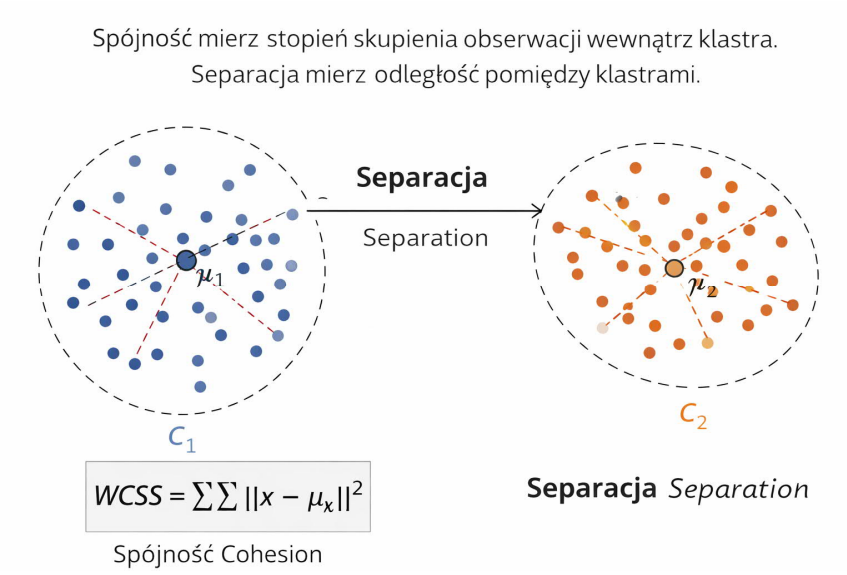

4. Wskaźnik Silhouette

Wskaźnik Silhouette (Silhouette Score) to miara jakości klasteryzacji, która jednocześnie ocenia spójność (cohesion) klastrów oraz ich separację (separation). Jest jedną z najczęściej stosowanych miar wewnętrznych (nie wymaga etykiet referencyjnych).

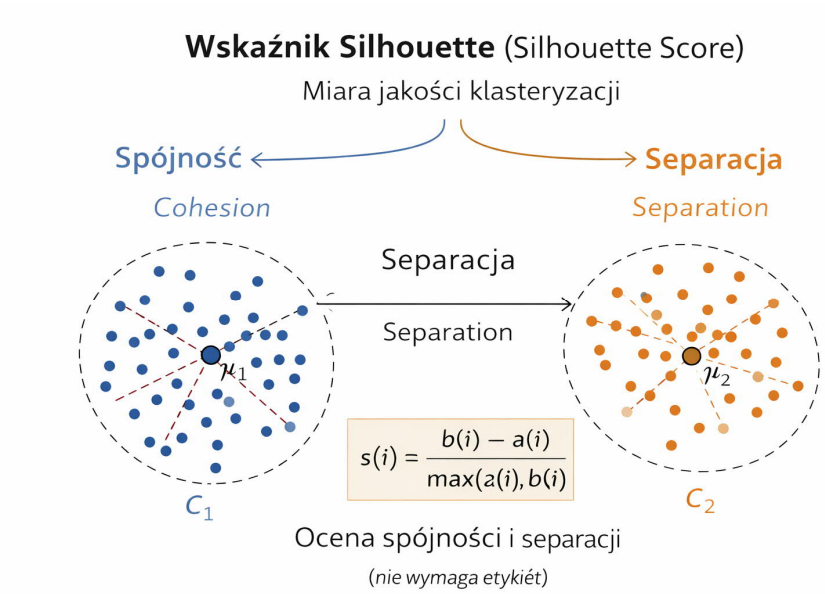

Dla obserwacji definiujemy:

$a(i)$ – średnią odległość do punktów w tym samym klastrze,
$b(i)$ – minimalną średnią odległość do punktów z innego klastra.

Wskaźnik Silhouette definiuje się jako:

$$s(i) = \big(b(i) - a(i)\big)/maxa(i), b(i).$$

Średnia wartość $s(i)$ dla wszystkich obserwacji stanowi miarę jakości całej klasteryzacji.

Zakres i interpretacja

Wartości wskaźnika mieszczą się w przedziale:

$$-1 \leq s(i) \leq 1$$

Interpretacja:

- $s(i) \approx 1 \rightarrow$ punkt bardzo dobrze przypisany do klastra
- $s(i) \approx 0 \rightarrow$ punkt leży na granicy klastrów
- $s(i) < 0 \rightarrow$ punkt prawdopodobnie przypisany do złego klastra

Średnia wartość Silhouette dla wszystkich punktów opisuje jakość całej klasteryzacji.

Intuicja

- Małe $a(i) \rightarrow$ punkt jest blisko „swoich”
- Duże $b(i) \rightarrow$ punkt jest daleko od „obcych”
- Dobra klasteryzacja → mała spójność + duża separacja

Silhouette łączy te dwa aspekty w jedną liczbę.

Zastosowania

- porównywanie różnych algorytmów klasteryzacji,
- dobór liczby klastrów K,
- ocena jakości podziału danych,
- wykrywanie źle przypisanych punktów.

5. Indeks Daviesa–Bouldina

Indeks Daviesa–Bouldina (DBI) definiuje się jako średnią maksymalnych stosunków rozproszenia klastrów do odległości między nimi:

$$DBI = (1/K)\Sigma max_j \neq i\big((Si + Sj)/Mij\big).$$

Niższe wartości DBI wskazują na lepszą separację klastrów.

6. Indeks Calinskiego–Harabasza

Indeks Calinskiego–Harabasza opiera się na stosunku wariancji międzyklastrowej do wewnątrzklastrowej:

$$CH = \big(Tr(B)/(K-1)\big)/\big(Tr(W)/(n-K)\big).$$

Wyższe wartości indeksu świadczą o lepszej strukturze klastrów.

7. Miary zewnętrzne jakości klastrów

W przypadku dostępności etykiet referencyjnych stosuje się miary zewnętrzne, takie jak Adjusted Rand Index (ARI) czy Normalized Mutual Information (NMI), które mierzą zgodność klasteryzacji z prawdziwym podziałem danych.

8. Stabilność klastrów

Stabilność klastrów ocenia się poprzez wielokrotne próbkowanie danych (bootstrap, subsampling) i porównywanie uzyskanych podziałów. Stabilne klastry są odporne na niewielkie zmiany danych.

9. Przykłady zastosowań

Miary jakości klastrów są szeroko stosowane w:
- segmentacji klientów w marketingu,
- analizie obrazów i rozpoznawaniu wzorców,
- biologii obliczeniowej (analiza ekspresji genów),
- wykrywaniu anomalii i fraudów.

Przykładowo, wysoka wartość Silhouette w segmentacji klientów wskazuje na wyraźnie rozdzielone grupy konsumentów.

10. Interpretacja wyników

Interpretując miary jakości klastrów należy uwzględniać charakter danych i algorytmu. Niska wartość DBI i wysoka wartość Silhouette sugerują dobrą jakość klasteryzacji, jednak zawsze zaleca się łączenie kilku miar oraz analizę wizualną.

11. Podsumowanie

Miary jakości klastrów stanowią kluczowy element analizy klasteryzacyjnej. Ich poprawne zastosowanie pozwala na obiektywną ocenę wyników oraz świadomy dobór algorytmu i liczby klastrów.

Przykład 1

Przykład klasteryzacji w Pythonie (K-Means) z oceną jakości (Silhouette) i prostą wizualizacją.

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import make_blobs
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score

# 1) Dane przykładowe (3 skupiska w 2D)
X, _ = make_blobs(n_samples=600, centers=3, cluster_std=1.2,
random_state=42)

# 2) Standaryzacja (ważne w klasteryzacji!)
X_scaled = StandardScaler().fit_transform(X)

# 3) Klasteryzacja K-Means
K = 3
kmeans = KMeans(n_clusters=K, n_init=10, random_state=42)
labels = kmeans.fit_predict(X_scaled)

# 4) Ocena jakości (Silhouette)
sil = silhouette_score(X_scaled, labels)
print(f"Silhouette score dla K={K}: {sil:.3f}")

# 5) Wizualizacja
plt.figure()
plt.scatter(X_scaled[:, 0], X_scaled[:, 1], c=labels)
centroids = kmeans.cluster_centers_
plt.scatter(centroids[:, 0], centroids[:, 1], marker="X", s=200)
plt.title(f"K-Means (K={K}) | Silhouette = {sil:.3f}")
plt.xlabel("Cecha 1 (standaryzowana)")
plt.ylabel("Cecha 2 (standaryzowana)")
plt.show()
```

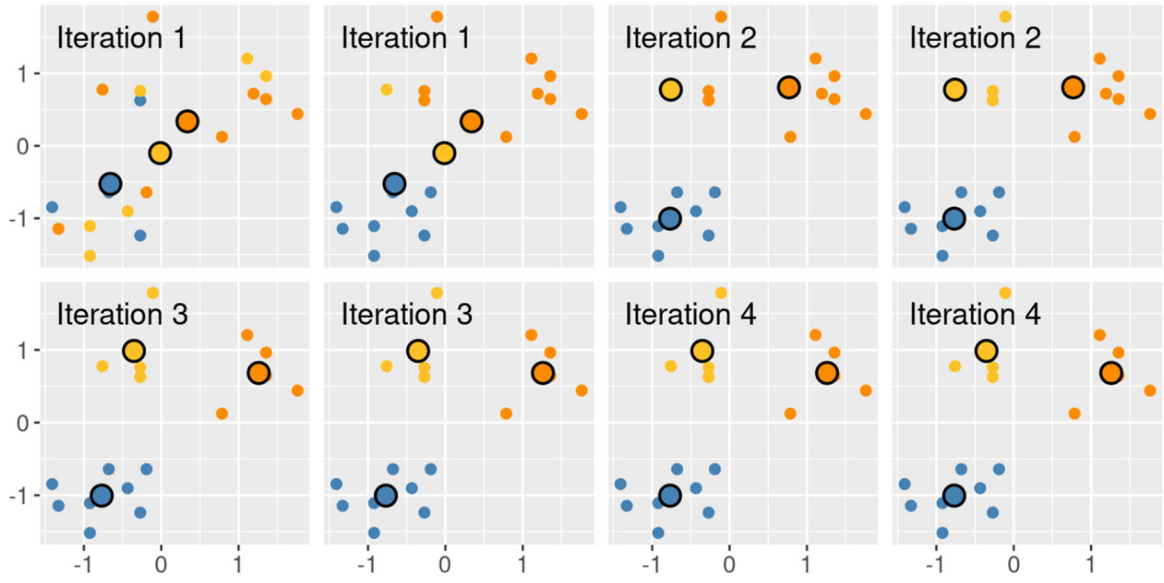
Iteration 1
Iteration 1
Iteration 2
Iteration 2
Iteration 3
Iteration 3
Iteration 4
Iteration 4

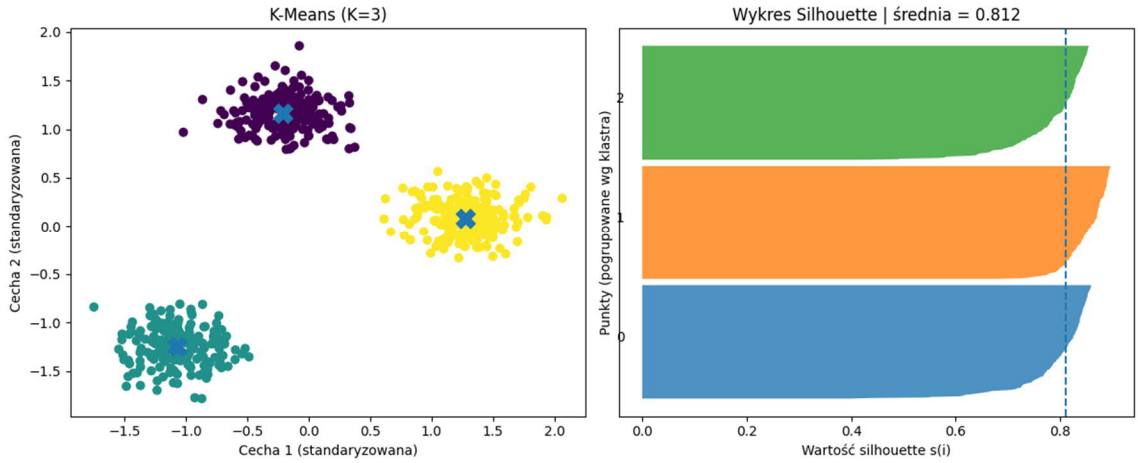
K-Means (K=3)
Cecha 1 (standaryzowana)
Cecha 2 (standaryzowana)
Wykres Silhouette | średnia = 0.812
Punkty (pogrupowane wg klastra)
Wartość silhouette s(i)