

Ćwiczenie laboratoryjne: Regresja wieloraka na przykładzie zbioru Energy Efficiency

Cel ćwiczenia

Celem zajęć jest praktyczne zapoznanie studentów z metodą regresji wielorakiej w analizie danych inżynierskich. Na podstawie rzeczywistych danych symulacyjnych zostanie zbudowany model przewidujący zapotrzebowanie na energię cieplną i chłodzenie budynków w zależności od ich parametrów konstrukcyjnych.

Zakres tematyczny

- przypomnienie pojęcia regresji liniowej i wielorakiej,
- wczytanie i przygotowanie danych,
- budowa modelu regresji wielorakiej,
- ocena dopasowania modelu (R^2 , RMSE, analiza reszt),
- interpretacja współczynników regresji,
- dyskusja nad zastosowaniami praktycznymi i ograniczeniami modelu.

Wprowadzenie teoretyczne

Regresja wieloraka to metoda statystyczna umożliwiająca modelowanie zależności między zmienną zależną Y a wieloma zmiennymi niezależnymi $X_1, X_2, \dots, X_k$. Ogólna postać modelu:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \varepsilon$$

gdzie Y to zmienna objaśniana, X_i to zmienne objaśniające, β_i to współczynniki regresji, a ε to składnik losowy. Model umożliwia ocenę siły i kierunku wpływu każdej zmiennej na wynik oraz prognozowanie wartości Y .

Opis danych: Energy Efficiency Dataset

Zbiór Energy Efficiency pochodzi z repozytorium UCI Machine Learning Repository i zawiera dane dotyczące budynków o różnych parametrach konstrukcyjnych i ich efektywności energetycznej.

Zmienna	Opis	Typ
Relative Compactness	zwartość budynku	ciągła
Surface Area	całkowita powierzchnia zewnętrzna	ciągła
Wall Area	powierzchnia ścian	ciągła
Roof Area	powierzchnia dachu	ciągła
Overall Height	wysokość budynku	ciągła

Orientation	kierunek ustawienia	kategoryczna
Glazing Area	procent powierzchni przeszkleń	ciągła
Glazing Area Distribution	rozmieszczenie okien	kategoryczna

Zmiennymi zależnymi są: Heating Load (zapotrzebowanie na ogrzewanie) oraz Cooling Load (zapotrzebowanie na chłodzenie).

Przebieg ćwiczenia

1. Wczytanie danych:

```
import pandas as pd

url = "https://archive.ics.uci.edu/ml/machine-learning-databases/00242/ENB2012_data.xlsx"
df = pd.read_excel(url)

df.columns = [
    'RelativeCompactness', 'SurfaceArea', 'WallArea', 'RoofArea',
    'OverallHeight', 'Orientation', 'GlazingArea',
    'GlazingAreaDistribution',
    'HeatingLoad', 'CoolingLoad'
]
print(df.head())
```

2. Budowa modelu regresji wielorakiej:

```
import statsmodels.api as sm

X = df[['RelativeCompactness', 'SurfaceArea', 'WallArea',
        'RoofArea',
        'OverallHeight', 'Orientation', 'GlazingArea',
        'GlazingAreaDistribution']]
y = df['HeatingLoad']
```

```
X = sm.add_constant(X)
model = sm.OLS(y, X).fit()
print(model.summary())
```

3. Ocena dopasowania modelu i analiza reszt:

```
import matplotlib.pyplot as plt

y_pred = model.predict(X)
residuals = y - y_pred

plt.scatter(y_pred, residuals)
plt.axhline(0, color='red', linestyle='--')
plt.xlabel("Wartości przewidywane")
```

```
plt.ylabel("Reszty")  
plt.title("Analiza reszt modelu")  
plt.show()
```

Pytania kontrolne

1. Co oznacza wysoka wartość współczynnika R^2 ?
2. Jak interpretować ujemny współczynnik przy zmiennej RelativeCompactness?
3. Dlaczego warto analizować reszty modelu?
4. W jaki sposób można rozszerzyć analizę, aby objąć zmienną Cooling Load?
5. Jakie ograniczenia ma model regresji wielorakiej w tym przypadku?

Wnioski

Po wykonaniu ćwiczenia student powinien umieć:

- zbudować model regresji wielorakiej,
- ocenić jego dopasowanie i interpretować współczynniki,
- rozumieć wpływ cech konstrukcyjnych na efektywność energetyczną,
- wskazać ograniczenia modelu i możliwe kierunki jego ulepszenia.