

Analiza: Energy Efficiency Dataset

Zbiór danych Energy Efficiency pochodzi z repozytorium UCI Machine Learning Repository i zawiera dane opisujące parametry budynków oraz ich wpływ na zapotrzebowanie na energię ciepłą (Heating Load) i chłodzenie (Cooling Load). Celem analizy jest budowa modelu regresji wielorakiej przewidującego efektywność energetyczną budynków na podstawie ich cech geometrycznych i materiałowych.

Struktura danych

Zbiór zawiera 768 obserwacji i 10 zmiennych, z czego 8 to zmienne niezależne, a 2 to zmienne zależne.

Nazwa zmiennej	Opis	Typ	Zakres
Relative Compactness	zwartość budynku (stosunek objętości do powierzchni zewnętrznej)	ciągła	0.62–0.98
Surface Area	całkowita powierzchnia zewnętrzna	ciągła	514.5–808.5
Wall Area	powierzchnia ścian	ciągła	245.0–416.5
Roof Area	powierzchnia dachu	ciągła	110.25–220.5
Overall Height	wysokość budynku	ciągła	3.5–7.0
Orientation	kierunek ustawienia (azymut: 2–5)	kategoryczna	2–5
Glazing Area	procent powierzchni przeszkleń	ciągła	0–0.4
Glazing Area Distribution	rozmieszczenie okien	kategoryczna	1–5

Zmiennymi zależnymi są: Heating Load (zapotrzebowanie na ogrzewanie) oraz Cooling Load (zapotrzebowanie na chłodzenie).

Cel analizy

Celem regresji jest przewidzenie zapotrzebowania na ogrzewanie i chłodzenie budynku na podstawie jego cech geometrycznych. Dane pozwalają na stworzenie dwóch modeli regresji lub jednego modelu wielowyjściowego (multi-output regression).

Przykładowa analiza w Pythonie

```
import pandas as pd
import statsmodels.api as sm

url = "https://archive.ics.uci.edu/ml/machine-learning-databases/00242/ENB2012_data.xlsx"
df = pd.read_excel(url)

df.columns = [
    'RelativeCompactness', 'SurfaceArea', 'WallArea', 'RoofArea',
    'OverallHeight', 'Orientation', 'GlazingArea',
    'GlazingAreaDistribution',
    'HeatingLoad', 'CoolingLoad'
]

X = df[['RelativeCompactness', 'SurfaceArea', 'WallArea',
        'RoofArea',
        'OverallHeight', 'Orientation', 'GlazingArea',
        'GlazingAreaDistribution']]
y = df['HeatingLoad']

X = sm.add_constant(X)
model = sm.OLS(y, X).fit()

print(model.summary())
```

Interpretacja wyników

Wynik regresji wielorakiej wykazuje bardzo wysoką wartość współczynnika determinacji ($R^2 \approx 0.99$), co oznacza, że model doskonale dopasowuje się do danych. Największy wpływ na zapotrzebowanie ciepłe mają: Relative Compactness i Overall Height, które obniżają Heating Load. Z kolei Surface Area i Wall Area zwiększają zapotrzebowanie na energię. Wartość Glazing Area silnie wpływa na Cooling Load – im więcej przeszkleń, tym większe zapotrzebowanie na chłodzenie.

Zastosowania praktyczne

- Projektowanie budynków energooszczędnych i pasywnych,
- Analiza wpływu architektury na zużycie energii,
- Weryfikacja zgodności z normami efektywności energetycznej,
- Badanie wpływu konstrukcji na komfort cieplny.

Uwagi i ograniczenia

Zbiór danych ma charakter syntetyczny (pochodzi z symulacji komputerowej), dlatego wyniki nie muszą dokładnie odzwierciedlać rzeczywistych budynków. Dodatkowo występuje korelacja między zmiennymi geometrycznymi, co może powodować współliniowość. Brak czynników klimatycznych ogranicza pełny kontekst analizy.

Podsumowanie

Zbiór Energy Efficiency stanowi doskonałą bazę dydaktyczną do nauki regresji wielorakiej. Łączy dane geometryczne, fizyczne i materiałowe, umożliwiając analizę wpływu wielu czynników na zużycie energii. Uzyskane modele są intuicyjne i łatwe do interpretacji, a sam zbiór stanowi wzorcowy przykład problemu inżynierskiego analizowanego metodami statystycznymi.