

Ćwiczenie: Regresja wieloraka w Pythonie

Celem ćwiczenia jest zbudowanie i zbadanie modelu regresji wielorakiej w języku Python z wykorzystaniem biblioteki scikit-learn oraz danych o cenach nieruchomości w Kalifornii. Zadanie pozwoli zrozumieć, jak wiele czynników jednocześnie wpływa na jedną zmienną wynikową.

Kod programu (Python):

```
# 1) Importy
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.datasets import fetch_california_housing
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score, mean_squared_error
import statsmodels.api as sm
from statsmodels.stats.outliers_influence import variance_inflation_factor

# 2) Dane
data = fetch_california_housing(as_frame=True)
df = data.frame.copy()
df.rename(columns={'MedHouseVal': 'y'}, inplace=True) # cel
(target)

# 3) Podział na zbiory
X = df.drop(columns=['y'])
y = df['y']

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)

# 4) Standaryzacja cech
scaler = StandardScaler()
X_train_s = scaler.fit_transform(X_train)
X_test_s = scaler.transform(X_test)

# 5) Uczenie modelu
lr = LinearRegression()
lr.fit(X_train_s, y_train)
```

```

# 6) Ocena
y_pred = lr.predict(X_test_s)
r2 = r2_score(y_test, y_pred)
rmse = mean_squared_error(y_test, y_pred, squared=False)
print(f"R^2: {r2:.3f}")
print(f"RMSE: {rmse:.3f}")

# 7) Współczynniki
coef = pd.Series(lr.coef_, index=X.columns).sort_values(key=abs,
ascending=False)
print(coef)

# 8) Diagnostyka
residuals = y_test - y_pred
plt.scatter(y_pred, residuals, s=8)
plt.axhline(0, ls='--')
plt.xlabel("Predykcja")
plt.ylabel("Reszty")
plt.title("Reszty vs predykcja")
plt.show()

sm.qqplot(residuals, line='45', fit=True)
plt.title("QQ-plot reszt")
plt.show()

# 9) VIF (kolinearność)
X_train_sm = sm.add_constant(pd.DataFrame(X_train_s,
columns=X.columns))
vif_table = pd.DataFrame({
    "feature": X.columns,
    "VIF": [variance_inflation_factor(X_train_sm.values, i+1)
           for i in range(len(X.columns))]
}).sort_values("VIF", ascending=False)
print(vif_table)

```

Opis danych (California Housing):

Dane pochodzą z amerykańskiego spisu powszechnego i zawierają informacje o nieruchomościach w stanie Kalifornia. Każdy rekord reprezentuje dane dla jednego obszaru (dzielnicy).

Zmienna objaśniana (target):

- y (MedHouseVal): mediana wartości domu (w setkach tysięcy USD).

Zmiennie objaśniające (cechy):

- MedInc – mediana dochodu w dziesiątkach tysięcy USD,
- HouseAge – średni wiek zabudowy mieszkaniowej,
- AveRooms – średnia liczba pokoi na gospodarstwo domowe,
- AveBedrms – średnia liczba sypialni,
- Population – liczba mieszkańców w obszarze,
- AveOccup – średnia liczba osób w gospodarstwie,
- Latitude, Longitude – współrzędne geograficzne lokalizacji.

Zbiór jest odpowiedni do analizy regresji wielorakiej, ponieważ zmienne wejściowe są różnorodne, częściowo skorelowane i mają sens ekonomiczny w kontekście cen nieruchomości.

Interpretacja wyników:

Wynik R^2 określa, jaki procent zmienności zmiennej y został wyjaśniony przez model. RMSE określa średni błąd predykcji w jednostkach oryginalnej zmiennej. Współczynniki regresji po standaryzacji wskazują względny wpływ każdej cechy. Analiza reszt i wykres QQ-plot pozwalają ocenić zgodność z założeniami modelu liniowego. Wysoki współczynnik VIF wskazuje na współliniowość między zmiennymi.

Rozszerzenia:

- Wprowadzenie transformacji nieliniowych (np. kwadratowych, logarytmicznych),
- Porównanie z modelami regularizowanymi (Ridge, Lasso),
- Analiza interakcji między zmiennymi (np. $\text{MedInc} \times \text{HouseAge}$).

Podsumowanie:

Regresja wieloraka pozwala jednocześnie analizować wpływ wielu czynników na jedną zmienną wynikową. Model z danymi California Housing dobrze obrazuje praktyczne zastosowanie metody w analizie zjawisk ekonomicznych, technicznych i społecznych.