

## Regresja wieloraka

### Definicja

Regresja wieloraka (ang. multiple linear regression) to metoda statystyczna, która bada zależność pomiędzy jedną zmienną zależną (objaśnianą) a wieloma zmiennymi niezależnymi (objaśniającymi).

### Model matematyczny

Model regresji wielorakiej opisuje równanie liniowe w postaci:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon$$

gdzie:

- $Y$  – zmienna zależna,
- $X_1, X_2, \dots, X_p$  – zmienne niezależne,
- $\beta_0$  – wyraz wolny,
- $\beta_i$  – współczynniki regresji,
- $\varepsilon$  – składnik losowy (błąd).

### Intuicja

Regresja wieloraka rozszerza prostą regresję liniową na przypadek wielu predyktorów. Pozwala ocenić, jak kilka czynników jednocześnie wpływa na zmienną zależną. Współczynnik  $\beta_i$  należy interpretować jako efekt danej zmiennej przy założeniu, że pozostałe zmienne są stałe.

### Przykład

Cena mieszkania ( $Y$ ) a czynniki objaśniające:

- Powierzchnia ( $X_1$ ),
- Liczba pokoi ( $X_2$ ),
- Odległość od centrum ( $X_3$ ).

Model:

$$\text{Cena} = 50\,000 + 3\,000 * \text{Powierzchnia} + 10\,000 * \text{Liczba pokoi} - 2\,000 * \text{Odległość} + \varepsilon$$

Interpretacja:

- każdy dodatkowy metr zwiększa cenę o 3 000,
- każdy dodatkowy pokój zwiększa cenę o 10 000,
- każdy kilometr dalej od centrum obniża cenę o 2 000.

### Zastosowania

- Ekonomia: prognozowanie cen, popytu, wydatków,
- Medycyna: analiza czynników ryzyka,

- Nauki społeczne: analiza danych z badań i ankiet,
- Inżynieria: modelowanie procesów.

### Założenia regresji wielorakiej

Aby model regresji wielorakiej był poprawnie interpretowany, powinny być spełnione następujące założenia:

1. Liniowość – zależność między zmienną zależną a zmiennymi niezależnymi jest liniowa.
2. Normalność reszt – składniki losowe (reszty) mają rozkład normalny ze średnią 0.
3. Homoscedastyczność – wariancja składników losowych jest stała dla wszystkich wartości predyktorów.
4. Niezależność reszt – błędy (reszty) nie są skorelowane ze sobą.
5. Brak współliniowości – zmienne niezależne nie są silnie skorelowane między sobą (niski VIF).
6. Brak wartości odstających i obserwacji wpływowych – pojedyncze punkty nie powinny nadmiernie wpływać na model.

### Diagnostyka i testy statystyczne

W celu weryfikacji założeń regresji wielorakiej stosuje się różne metody diagnostyczne i testy statystyczne:

1. Liniowość – sprawdzana wizualnie za pomocą wykresu reszt względem wartości dopasowanych; brak wzorca oznacza poprawne założenie.
2. Normalność reszt – test Jarque-Bera, Shapiro-Wilka lub wizualnie za pomocą QQ-plot. Odrzucenie hipotezy zerowej sugeruje nienormalność reszt.
3. Homoscedastyczność – test Breusch-Pagana lub White'a;  $p\text{-value} < 0.05$  oznacza heteroscedastyczność (wariancja reszt nie jest stała).
4. Niezależność reszt – test Durbin-Watsona (wartości bliskie 2 sugerują brak autokorelacji).
5. Brak współliniowości – współczynnik VIF (Variance Inflation Factor); wartości  $> 5\text{--}10$  mogą wskazywać na problem.
6. Wartości odstające i obserwacje wpływowe – analiza odległości Cooka oraz dźwigni (leverage). Obserwacje o dużych wartościach mogą znacząco wpływać na wyniki.

## Przykłady w Pythonie: diagnostyka regresji

### Importy i przygotowanie danych (California Housing)

```
import numpy as np
import pandas as pd
import statsmodels.api as sm
from statsmodels.stats.diagnostic import het_breuschpagan, het_white
from statsmodels.stats.stattools import jarque_bera
from statsmodels.stats.outliers_influence import
variance_inflation_factor, OLSInfluence
from sklearn.datasets import fetch_california_housing
from sklearn.model_selection import train_test_split
```

```
# Dane
```

```
data = fetch_california_housing(as_frame=True)
df = data.frame.rename(columns={'MedHouseVal': 'y'})
```

```
# Podział na train/test
```

```
X = df.drop(columns='y')
y = df['y']
X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.2, random_state=42)
```

```
# Dodanie stałej i dopasowanie OLS
```

```
X_train_sm = sm.add_constant(X_train)
model = sm.OLS(y_train, X_train_sm).fit()
resid = model.resid
print(model.summary())
```

### QQ-plot reszt (sprawdzenie normalności)

```
import matplotlib.pyplot as plt
sm.qqplot(resid, line='45', fit=True)
plt.title('QQ-plot reszt')
plt.show()
```

### Test Jarque–Bera (normalność reszt)

```
jb_stat, jb_p, skew, kurt = jarque_bera(resid)
print(f'Jarque-Bera: stat={jb_stat:.3f}, p={jb_p:.3g}, skew={skew:.3f},
kurt={kurt:.3f}')
```

### Test Breusch–Pagan (heteroscedastyczność)

```
bp_stat, bp_p, _, _ = het_breuschpagan(resid, X_train_sm)
print(f'Breusch-Pagan: stat={bp_stat:.3f}, p={bp_p:.3g}')
```

### Test White'a (heteroscedastyczność)

```
w_stat, w_p, _, _ = het_white(resid, X_train_sm)
print(f'White: stat={w_stat:.3f}, p={w_p:.3g}')
```

### Współczynnik Durbin–Watsona (autokorelacja reszt)

```
from statsmodels.stats.stattools import durbin_watson
dw = durbin_watson(resid)
print(f'Durbin-Watson: {dw:.3f} (~2 oznacza brak autokorelacji)')
```

### VIF – współliniowość predyktorów

```
import pandas as pd
vif_df = pd.DataFrame({
    'feature': X_train_sm.columns,
    'VIF': [variance_inflation_factor(X_train_sm.values, i) for i in
range(X_train_sm.shape[1])]
})
print(vif_df)
```

### Obserwacje wpływowe: odległość Cooka i dźwignia

```
influence = OLSInfluence(model)
cooks_d = influence.cooks_distance[0] # wartości Cooka
leverage = influence.hat_matrix_diag # dźwignia

# Top 10 najbardziej wpływowych obserwacji (wg Cooka)
idx = np.argsort(cooks_d)[-10:][::-1]
print(pd.DataFrame({'index': idx, 'cooks_distance': cooks_d[idx],
'leverage': leverage[idx]}))
```

### Robust standard errors (HC3) – odporne błędy standardowe

```
robust = model.get_robustcov_results(cov_type='HC3')
print(robust.summary())
```

## Omówienie przykładów diagnostyki regresji

### QQ-plot reszt (normalność)

QQ-plot pozwala sprawdzić, czy rozkład reszt jest zbliżony do normalnego. Jeżeli punkty układają się wzdłuż linii 45°, oznacza to przybliżoną normalność. Znaczne odchylenia w ogonach sugerują skośność lub nadmierną kurtozę.

### Test Jarque–Bera

Formalny test statystyczny normalności reszt. Hipoteza zerowa zakłada rozkład normalny. Jeżeli  $p\text{-value} < 0.05$ , odrzucamy  $H_0$  i stwierdzamy, że reszty nie są normalne.

### Test Breusch–Pagana

Służy do wykrywania heteroscedastyczności.  $H_0$ : wariancja reszt jest stała. Jeżeli  $p\text{-value} < 0.05$ , oznacza to naruszenie założenia homoscedastyczności.

### Test White'a

Alternatywny test heteroscedastyczności, mniej restrykcyjny niż Breusch–Pagan. Również tu niskie  $p\text{-value}$  oznacza heteroscedastyczność.

### Wskaźnik Durbin–Watsona

Mierzy autokorelację reszt. Wartość bliska 2 oznacza brak autokorelacji. Wartości niższe od 2 sugerują dodatnią autokorelację, wyższe od 2 – ujemną.

### VIF – współliniowość

Variance Inflation Factor pokazuje, na ile zmienna jest skorelowana z innymi predyktorami. VIF > 5–10 może wskazywać na poważny problem współliniowości.

### Odległość Cooka i dźwignia

Te miary pozwalają wykryć obserwacje wpływowe. Duża wartość Cooka oznacza, że pojedyncza obserwacja silnie wpływa na wyniki modelu. Duża dźwignia wskazuje, że obserwacja ma nietypowe wartości predyktorów.

### Robust standard errors (HC3)

O odporne błędy standardowe warto zadbać w przypadku heteroscedastyczności. Współczynniki się nie zmieniają, ale błędy standardowe i p-value są bardziej wiarygodne.