

Do czego służy regresja logistyczna?

Regresja logistyczna to metoda statystyczna służąca do oceny wpływu wielu czynników (zmiennych niezależnych, inaczej objaśniających) na prawdopodobieństwo wystąpienia określonego zdarzenia. Przykładami mogą być:

- prawdopodobieństwo zachorowania na chorobę,
- szansa terminowej spłaty kredytu,
- prawdopodobieństwo zakupu produktu przez klienta.

Szansa, prawdopodobieństwo i ryzyko – wyjaśnienie pojęć

Zanim przejdziemy do samej regresji, warto uporządkować znaczenie trzech pokrewnych terminów: prawdopodobieństwo, szansa i ryzyko.

Prawdopodobieństwo

To stosunek liczby przypadków sprzyjających danemu zdarzeniu do liczby wszystkich możliwych przypadków. Przykład: jeśli w pudełku znajdują się trzy białe i jedna czarna kulka, to prawdopodobieństwo wylosowania czarnej wynosi:

$$P = 1 / 4 = 0,25$$

Szansa (odds)

Szansa to stosunek liczby przypadków sprzyjających danemu zdarzeniu do liczby przypadków, które mu nie sprzyjają. W tym samym przykładzie szansa wylosowania czarnej kulki wynosi:

$$\text{odds} = 1 / 3 \approx 0,33$$

Widzimy więc, że „prawdopodobieństwo” i „szansa” to różne pojęcia — choć w języku potocznym często używamy ich zamiennie.

Ryzyko

Słowo „ryzyko” w języku codziennym oznacza możliwość wystąpienia zdarzenia niekorzystnego, np. „ryzyko zgonu”. W statystyce jednak pojęcie to jest często utożsamiane z prawdopodobieństwem niekorzystnego zdarzenia. Dlatego, aby uniknąć niejednoznaczności, w kontekście regresji logistycznej lepiej mówić o szansach (odds) niż o ryzyku.

Podsumowanie

Regresja logistyczna pozwala na ilościową ocenę, w jakim stopniu poszczególne zmienne (np. wiek, płeć, styl życia) wpływają na szanse wystąpienia zdarzenia. Dzięki temu możemy

modelować i przewidywać zjawiska o charakterze zero-jedynkowym, takie jak „choroba – brak choroby” lub „zakup – brak zakupu”.

Omówienie przykładu regresji logistycznej (jednowymiarowej)

W poniższym omówieniu przedstawiono działanie kodu implementującego regresję logistyczną dla jednej zmiennej objaśniającej (wiek) oraz interpretację współczynników i wyniku predykcji.

Kod programu

```
import pandas as pd
import math

from sklearn.linear_model import LogisticRegression

from platform import python_version
from sklearn import __version__ as sklearn_ver
from statsmodels import __version__ as statsmodels_ver

print(f'python: {python_version()}')
print(f'\npandas: {pd.__version__}')
print(f'sklearn: {sklearn_ver}')
print(f'statsmodels: {statsmodels_ver}')

df = pd.read_excel('data.xlsx')
df.head(3)

X = df[['age']]
y = df['target']

model = LogisticRegression()
model.fit(X, y)

# probability of death
age_to_predict = 30
model.predict_proba([[age_to_predict]])[:,1]

theta0 = model.intercept_[0]
```

```
theta1 = model.coef_[0][0]

print(f'theta1={round(theta1,3)}; theta0 ={round(theta0,3)}')

# probability of death from math formula
round(1/(1+math.exp(-(age_to_predict*theta1+theta0))),8)
```

1. Opis działania kodu

Skrypt wczytuje dane z pliku Excel (`data.xlsx`), gdzie kolumna `age` reprezentuje wiek, a kolumna `target` to zmienna binarna (np. 1 – zgon, 0 – przeżycie). Następnie tworzy model regresji logistycznej z pakietu scikit-learn i uczy go zależności pomiędzy wiekiem a prawdopodobieństwem zdarzenia.

Po nauczaniu modelu, wykonywana jest predykcja dla przykładowego wieku (30 lat), a następnie obliczane są współczynniki: θ_0 (intercept) oraz θ_1 (nachylenie). Wynik `predict\_proba` odpowiada wartości funkcji sigmoidalnej:

$$p(x) = 1 / (1 + e^{-(\theta_0 + \theta_1 \cdot x)})$$

2. Interpretacja współczynników

- θ_1 – oznacza przyrost log-ilorazu szans (log-odds) dla wzrostu wieku o 1 jednostkę (rok). Jeśli $e^{\theta_1} > 1$, starszy wiek zwiększa szanse zdarzenia; jeśli < 1 , zmniejsza.
- θ_0 – ustala punkt przecięcia (wartość logitu dla wieku = 0), przesuwając krzywą sigmoidalną na osi x.

Model uczy zależność typu:

$$\log(p/(1-p)) = \theta_0 + \theta_1 \cdot \text{age}$$

czyli liniową relację pomiędzy logarytmem ilorazu szans a wiekiem.

3. Obliczanie ręczne

Zastosowanie funkcji `math.exp` i wzoru na sigmoidalną pozwala ręcznie odtworzyć wynik predykcji `predict\_proba`. Obie metody – modelowa i matematyczna – powinny dawać identyczne rezultaty po zaokrągleniu.

4. Uwagi praktyczne

- Przy wielu zmiennych lub dużej skali warto dodać standaryzację (StandardScaler).
- Domyślnie regresja w scikit-learn używa regularyzacji L2; do czystego MLE można użyć `penalty='none'` lub pakietu `statsmodels`.
- Dla danych niezbalansowanych warto ustawić `class\_weight='balanced'`.
- Model logistyczny jest probabilistyczny – należy oceniać jego kalibrację i miary takie jak AUC-ROC, AUC-PR, Brier score.

5. Rozszerzenie – przykład obliczeń

Przykład dodatkowego kodu do oceny modelu:

```
import numpy as np, math
from sklearn.metrics import roc_auc_score, brier_score_loss

p = model.predict_proba(X)[:,-1]
print("AUC:", roc_auc_score(y, p))
print("Brier:", brier_score_loss(y, p))
print("OR (per year):", math.exp(theta1))
age50_p = 1/(1+math.exp(-(theta0+theta1*50)))
print("P(Y=1 | age=50):", age50_p)
```

6. Podsumowanie

Kod pokazuje, jak na prostym przykładzie jednowymiarowym zweryfikować równanie regresji logistycznej. Funkcja `predict_proba` i wzór matematyczny sigmoidy zwracają te same wartości. Parametr θ_1 określa kierunek i siłę wpływu wieku na prawdopodobieństwo zdarzenia, a $e^{\{\theta_1\}}$ interpretujemy jako zmianę ilorazu szans dla wzrostu wieku o 1 rok.

Materiały:

<https://mirosławmamczur.pl/jak-działa-regresja-logistyczna/>

<https://www.datacamp.com/tutorial/understanding-logistic-regression-python>

<https://www.kaggle.com/code/prashant111/logistic-regression-classifier-tutorial>