

Zadanie: Regresja logistyczna – prawdopodobieństwo, szansa (odds) i kalibracja

Celem zadania jest praktyczne zrozumienie regresji logistycznej oraz różnicy między prawdopodobieństwem, szansą (odds) i logitem. W ćwiczeniu zbudujesz model klasyfikacji binarnej, zbadacie jego skuteczność, skalibrujecie predykcje i zinterpretujecie współczynniki w kategoriach ilorazów szans.

1. Dane i przygotowanie

Użyj wbudowanego zbioru danych ``breast_cancer`` z pakietu `scikit-learn`. Podziel dane na zbiór uczący i testowy (75%–25%) z zachowaniem proporcji klas. Następnie zbuduj pipeline złożony z:

- standaryzacji (``StandardScaler``),
- modelu ``LogisticRegression`` z wagami klas (`balanced`), solverem ``lbfgs``, ``max_iter=500``.

Zapisz przewidywane prawdopodobieństwa dla zbioru testowego.

Miejsce na kod i komentarz:

2. Prawdopodobieństwo, szansa (odds) i logit

Policz dla kilku obserwacji:

- prawdopodobieństwo: p ,
- szansę (odds): $p / (1 - p)$,
- logit: $\log(p / (1 - p))$.

Porównaj wartości i opisz zależność między nimi.

Miejsce na tabelę / rzut wyników:

3. Ocena jakości modelu

Oceń model przy użyciu następujących miar:

- AUC-ROC,
- AUC-PR,
- Brier score.

Zinterpretuj wartości – co oznacza wysoka lub niska wartość każdej z metryk.

Miejsce na wyniki metryk:

4. Kalibracja modelu

Porównaj model bazowy (nieskalibrowany) z modelami skalibrowanymi metodami:

- Platt (sigmoid),
- Izotoniczną.

Dla każdego modelu oblicz Brier score i narysuj krzywe kalibracji (reliability plot).

Miejsce na wykres kalibracji:

5. Dobór progu decyzyjnego

Użyj krzywej ROC i wskaźnika Youdena (TPR - FPR), aby znaleźć optymalny próg klasyfikacji. Dla tego progu przedstaw macierz pomyłek i opisz wnioski (czy model częściej popełnia błędy typu I czy II).

Miejsce na macierz pomyłek i interpretację:

6. Interpretacja współczynników

Wyświetl współczynniki regresji β oraz oblicz ilorazy szans e^{β} . Zidentyfikuj 5 cech o największym wpływie na decyzję modelu i opisz ich interpretację.

Miejsce na tabelę współczynników:

7. Wnioski końcowe

Podsumuj obserwacje:

- Czy model był dobrze skalibrowany?
- Jakie cechy miały największy wpływ?
- Czy wybrany próg poprawił wyniki klasyfikacji?
- Jak rozumiesz różnicę między prawdopodobieństwem, szansą i logitem?

Miejsce na podsumowanie:

Załącznik: szkic kodu (Python, scikit-learn)

Poniższy kod realizuje kolejne kroki zadania: przygotowanie danych, model bazowy, kalibracja (Platt, izotoniczna), metryki, krzywe kalibracji oraz dobór progu Youdena. Skopiuj do notatnika Jupyter lub pliku .py i uruchom.

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.datasets import load_breast_cancer
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import Pipeline
from sklearn.linear_model import LogisticRegression
from sklearn.calibration import CalibratedClassifierCV,
calibration_curve
from sklearn.metrics import (roc_auc_score,
                             average_precision_score,
                             brier_score_loss, confusion_matrix,
                             roc_curve)

# 1) Dane
X, y = load_breast_cancer(return_X_y=True, as_frame=True)

# 2) Podział
Xtr, Xte, ytr, yte = train_test_split(X, y, test_size=0.25,
                                       stratify=y, random_state=42)

# 3) Pipeline: standaryzacja + LR (L2)
base = Pipeline([
    ("sc", StandardScaler()),
    ("lr", LogisticRegression(max_iter=500,
                              class_weight="balanced", solver="lbfgs"))
])
base.fit(Xtr, ytr)
p_base = base.predict_proba(Xte)[:, 1] # prawdopodobieństwa p

# 4) Prawdopodobieństwo vs. szansa vs. logit
def odds(p): return p / (1 - p)
def logit(p): return np.log(p / (1 - p))
ex = pd.DataFrame({"p": p_base[:5],
                   "odds": odds(p_base[:5]),
                   "logit": logit(p_base[:5])})
print("\nProb/odds/logit (pierwsze 5):\n", ex.round(4))
```

```

# 5) Metryki bazowe
auc = roc_auc_score(yte, p_base)
apr = average_precision_score(yte, p_base)
brier = brier_score_loss(yte, p_base)
print(f"\nBazowo: AUC-ROC={auc:.3f}  AUC-PR={apr:.3f}
Brier={brier:.3f}")

# 6) Kalibracja: Platt i izotoniczna
platt = CalibratedClassifierCV(base, method="sigmoid",
cv=5).fit(Xtr, ytr)
iso = CalibratedClassifierCV(base, method="isotonic",
cv=5).fit(Xtr, ytr)
p_platt = platt.predict_proba(Xte)[: , 1]
p_iso = iso.predict_proba(Xte)[: , 1]

print("Platt  Brier:", brier_score_loss(yte, p_platt))
print("Iso    Brier:", brier_score_loss(yte, p_iso))

# 7) Krzywe kalibracji
fig, ax = plt.subplots(figsize=(6,4))
for name, p in [("NoCal", p_base), ("Platt", p_platt),
("Isotonic", p_iso)]:
    frac_pos, mean_pred = calibration_curve(yte, p, n_bins=10,
strategy='quantile')
    ax.plot(mean_pred, frac_pos, marker='o', label=name)
ax.plot([0,1], [0,1], 'k--', lw=1)
ax.set_xlabel("Prognozowane p")
ax.set_ylabel("Częstość rzeczywista")
ax.set_title("Kalibracja (reliability plot)")
ax.legend(); plt.tight_layout(); plt.show()

# 8) Próg decyzyjny (Youden) - na izotonicznie skalibrowanym
wariancie
fpr, tpr, thr = roc_curve(yte, p_iso)
best_idx = np.argmax(tpr - fpr)
thr_best = thr[best_idx]
print(f"Próg Youdena: {thr_best:.3f} (TPR={tpr[best_idx]:.3f},
FPR={fpr[best_idx]:.3f}")

yhat = (p_iso >= thr_best).astype(int)
print("Macierz pomyłek @Youden:\n", confusion_matrix(yte, yhat))

# 9) Współczynniki i OR
lr = base.named_steps["lr"]
coefs = lr.coef_.ravel()

```

```
or_df = pd.DataFrame({
    "cecha": X.columns,
    "beta": coefs,
    "odds_ratio": np.exp(coefs)
}).sort_values("odds_ratio", ascending=False)
print("\nTop ilorazy szans:\n", or_df.head(10).round(3))
```