

Propozycje zbiorów danych do regresji logistycznej

Poniżej przedstawiono zestaw przykładowych zbiorów danych, które można wykorzystać do realizacji ćwiczeń z regresji logistycznej – zarówno prostych, jak i zaawansowanych. Zbiory podzielono na trzy grupy: wbudowane, publiczne oraz domenowe.

1. Wbudowane zbiory danych (scikit-learn, seaborn)

Nazwa	Liczba klas	Opis	Import / źródło
Breast Cancer	2	Diagnoza guza piersi (łagodny / złośliwy).	from sklearn.datasets import load_breast_cancer
Iris	3	Klasyfikacja gatunków irysa.	from sklearn.datasets import load_iris
Wine	3	Klasyfikacja win na podstawie składu chemicznego.	from sklearn.datasets import load_wine
Digits	10	Klasyfikacja cyfr 0–9 (można uprościć do binarnej).	from sklearn.datasets import load_digits
Titanic	2	Przeżycie pasażerów Titanica (regresja logistyczna).	sns.load_dataset('titanic')

2. Publicznie dostępne zbiory danych (UCI, Kaggle, OpenML)

Nazwa	Źródło / link	Opis
Pima Indians Diabetes	https://archive.ics.uci.edu/ml/datasets/pima+indians+diabetes	Cukrzyca u kobiet z plemienia Pima – klasyczny benchmark.

Heart Disease	https://www.kaggle.com/ronitf/heart-disease-uci	Ryzyko choroby serca – dane medyczne.
Bank Marketing	https://archive.ics.uci.edu/ml/datasets/bank+marketing	Czy klient banku zgodzi się na depozyt terminowy.
Adult (Census Income)	https://archive.ics.uci.edu/ml/datasets/adult	Czy osoba zarabia >50K\$/rok – klasyka ML.
Student Performance	https://archive.ics.uci.edu/ml/datasets/student+performance	Wyniki uczniów a czynniki społeczne.
Credit Default	https://www.kaggle.com/uciml/default-of-credit-card-clients-dataset	Przewidywanie spłaty kredytu.

3. Zbiory domenowe (większe, realistyczne dane)

Nazwa	Dziedzina	Cel / zastosowanie
Churn Prediction (Telco)	Marketing / CRM	Czy klient odejdzie z usługi.
Fraud Detection	Finanse	Wykrywanie oszustw płatniczych.
Loan Default	Bankowość	Czy klient spłaci kredyt.
Medical Diagnosis	Medycyna	Klasyfikacja pacjentów: chory / zdrowy.

Wskazówki:

- Upewnij się, że zmienna docelowa jest binarna (0/1).
- Przeskaluj cechy numeryczne (`StandardScaler`).
- Sprawdź brakujące wartości i współliniowość.
- Dla klas niezbalansowanych stosuj `class\_weight='balanced'` lub SMOTE.