

Zadanie:

Porównanie modeli klasyfikacyjnych i ocena niepewności estymacji

Cel ćwiczenia

Celem ćwiczenia jest porównanie jakości kilku modeli klasyfikacyjnych oraz ocena wpływu niepewności estymacji na wyniki predykcyjne. Użyj walidację krzyżową do obliczenia średniej dokładności oraz odchylenia standardowego wyników, a następnie wybierz najlepszy model na podstawie uzyskanych rezultatów.

Ogólne omówienie

Dla zbioru danych z repozytorium UCI Machine Learning Repository Breast Cancer

```
from sklearn.datasets import load_breast_cancer

data = load_breast_cancer()
X = data.data
y = data.target
```

Zbuduj cztery różne modele klasyfikacyjne: **Logistic Regression, Random Forest, SVM i KNN**.

Do oceny ich jakości zastosuj metodę walidacji krzyżowej **k-fold (k=5)**, która polega na wielokrotnym podziale danych na zbiór treningowy i testowy.

Dla każdego modelu oblicz średnią dokładność (accuracy), która określa ogólną jakość predykcji, oraz odchylenie standardowe, które informuje o stabilności modelu i niepewności estymacji wyników.

Model o najwyższej średniej dokładności i najmniejszej zmienności wyniku jest uznawany za najlepszy.

Rozwiązanie ma zawierać:

1. Przedstaw kod w języku Python,
2. Przedstaw wyniki w postaci wycinka ekranu działającego programu,
3. Wnioski, udziel odpowiedzi:
 - o Co oznacza, że zbiór danych jest „dobrze rozdzielny” w kontekście klasyfikacji?
 - o Czy model o wysokiej średniej accuracy, ale bardzo dużym odchyleniu standardowym można uznać za stabilny? Dlaczego tak / dlaczego nie?
 - o Co mierzy odchylenie standardowe wyników w cross-validation i jak interpretujesz niską wartość tej miary?
 - o Co rozumiemy przez „niepewność estymacji” w kontekście oceny jakości modelu?
 - o Podaj przykład sytuacji, w której dwa modele mają podobną średnią accuracy, ale różną niepewność estymacji. Który model wybrałbyś i dlaczego?

Opis zbioru danych – Breast Cancer

Zbiór **Breast Cancer Wisconsin (Diagnostic)** pochodzi z **UCI Machine Learning Repository**, jednego z najpopularniejszych repozytoriów danych do badań nad uczeniem maszynowym. Dane pochodzą z badań nad rozpoznawaniem nowotworu piersi na podstawie cyfrowego obrazu biopsji .

Cel zbioru

Celem datasetu jest klasyfikacja wykrytego guza jako:

- **benign (B)** – łagodny,
- **malignant (M)** – złośliwy.

Zadanie polega na stworzeniu modelu predykcyjnego, który potrafi automatycznie ocenić charakter zmiany na podstawie zmierzonych cech struktury komórek.

PARAMETR	WARTOŚĆ
LICZBA PRÓBEK	569
LICZBA CECH (FEATURES)	30 wartości numerycznych

LICZBA KLAS	2 (Malignant / Benign)
FORMAT DANYCH	wartości liczbowe typu float
BRAKUJĄCE DANE	brak missing values
ŹRÓDŁO DANYCH	Szpital Uniwersytetu Wisconsin, Madison

Opis cech

Każda próbka opisuje właściwości jądra komórkowego wykryte na obrazie mikroskopowym. Dla 10 podstawowych parametrów obliczono trzy typy statystyk:

- mean – średnia z wielokrotnych pomiarów,
- se – błąd standardowy (zmienność między komórkami),
- worst – największa wartość (najbardziej skrajny pomiar).

To właśnie te cechy umożliwiają modelom ML rozróżnienie nowotworów łagodnych od złośliwych.

Podstawowe parametry morfologiczne

- promień (*radius*) – średnia odległość od centrum do granicy komórki
- tekstura (*texture*) – zróżnicowanie intensywności pikseli
- obwód (*perimeter*)
- powierzchnia (*area*)
- wygładzenie (*smoothness*)
- zwartość (*compactness*)
- wklęsłość (*concavity*)
- liczba wklęsłych fragmentów (*concave points*)
- symetria
- fraktalność

